# Statystyczna analiza danych

dokumentacja projektu laboratoryjnego

Czerniak Kacper, grupa 1 Wasik Wojciech, grupa 1

26 stycznia 2026

# 1 Wprowadzenie

## 1.1 Opis danych

Analizie poddano zbiór danych zawierający informacje o samochodach marki BMW dostępnych na rynku wtórnym. Dane obejmują zarówno cechy ilościowe, jak i jakościowe pojazdów, w szczególności:

- cenę pojazdu,
- rok produkcji,
- przebieg,
- pojemność silnika,
- rodzaj paliwa,
- typ skrzyni biegów,
- model samochodu.

Zbiór danych charakteryzuje się dużą liczebnością obserwacji, co umożliwia zastosowanie zarówno metod parametrycznych, jak i nieparametrycznych. Dominują pojazdy z silnikiem Diesla oraz samochody wyprodukowane po roku 2015. Celem analizy jest zbadanie zależności pomiędzy ceną samochodu a jego cechami technicznymi i eksploatacyjnymi.

## 1.2 Podstawowe parametry statystyczne

Analiza statystyk opisowych wskazuje, że średnia cena samochodu BMW wynosi około 22 700, natomiast mediana około 20 500, co sugeruje prawostronną skośność rozkładu cen. Obecność samochodów o bardzo wysokich cenach powoduje zawyżenie średniej względem mediany.

Większość pojazdów pochodzi z lat 2016–2019, a średni rok produkcji wynosi około 2017. Przebieg samochodów charakteryzuje się dużym zróżnicowaniem – mediana znajduje się na poziomie kilkudziesięciu tysięcy kilometrów, natomiast wartości maksymalne przekraczają 200 tysięcy kilometrów, co wskazuje na obecność obserwacji odstających.

Histogram rozkładu cen (Rysunek 1) pokazuje silną asymetrię oraz koncentrację obserwacji w przedziale od 10 000 do 30 000. Zależność ceny od przebiegu (Rysunek 2) wskazuje na wyraźną ujemną korelację – wraz ze wzrostem przebiegu cena pojazdu zazwyczaj maleje, przy czym dla niskich przebiegów obserwuje się dużą zmienność cen.

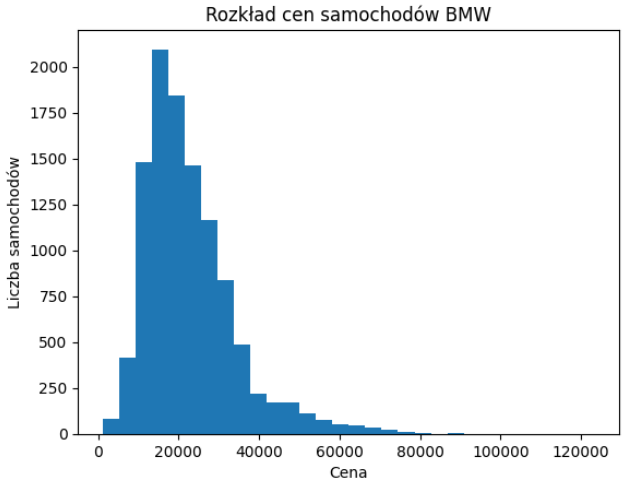


Rysunek 1: Rozkład cen samochodów BMW

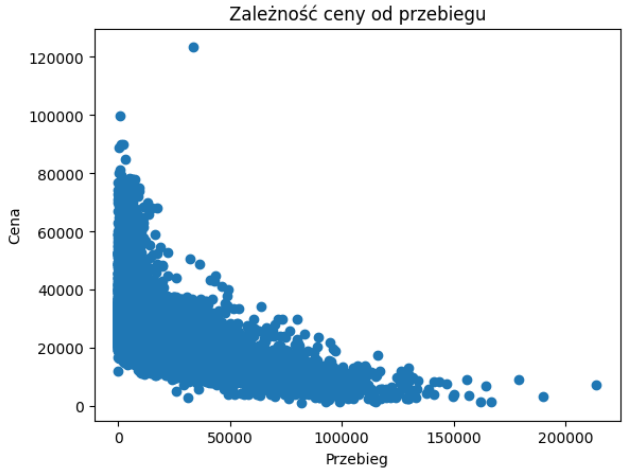


Rysunek 2: Zależność ceny samochodu od jego przebiegu

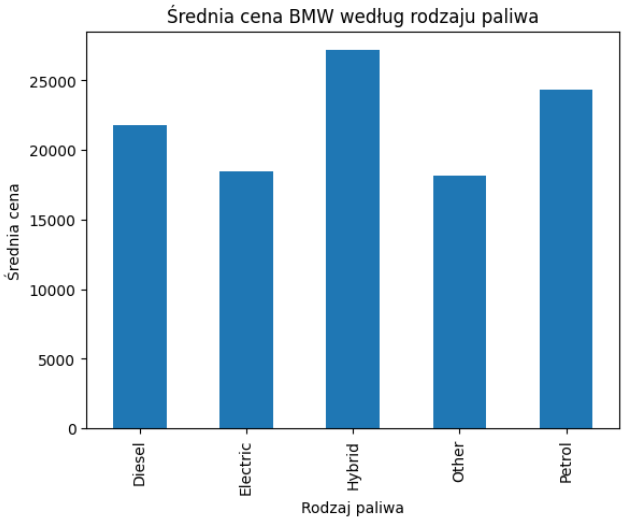


Rysunek 3: Średnia cena według rodzaju paliwa

## 1.3 Macierz koleracji

Z macierzy koleracji można zauważyć, że najsilniej ze sobą skorelowane są Rok Produkcji i Cena (im nowsze auto tym droższe) oraz silną kolerację odwrotną mają cena i rok produkcji z przebiegiem. (im wyższy przebieg tym niższa cena i im nowsze auto tym mniejszy przebieg).

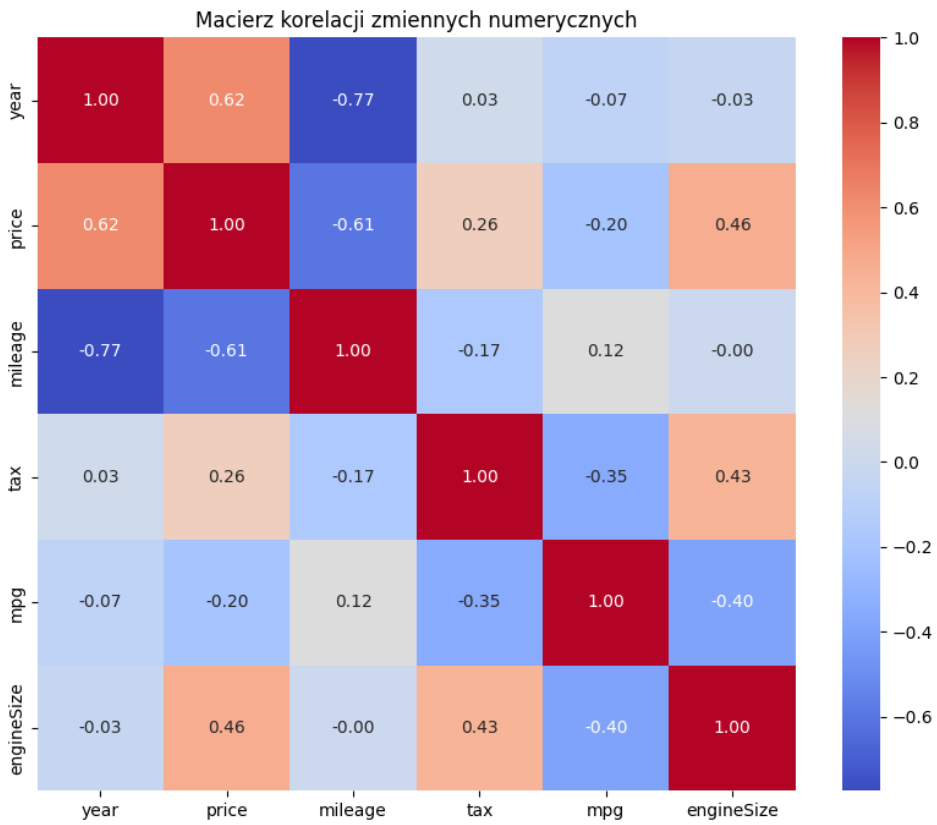


Rysunek 4: Macierz koleracji

# 2 Testy parametryczne

Przyjęto standardowy poziom istotności statystycznej $\alpha = 0.05$.

## 2.1 Test t-Studenta

Celem testu t-Studenta jest sprawdzenie, czy średnia cen samochodów BMW z silnikiem Diesla i benzynowym różnią się w sposób istotny statystycznie.

### 2.1.1 Hipotezy

- Hipoteza zerowa ($H_0$): średnia cen samochodów z silnikiem Diesla nie różni się istotnie statystycznie względem średniej cen samochodów benzynowych.
- Hipoteza alternatywna ($H_1$): średnie cen samochodów z silnikiem Diesla i benzynowych różnią się istotnie statystycznie.

### 2.1.2 Założenia testu

Test t-Studenta wymaga spełnienia następujących założeń:

1. Niezależność prób – każda obserwacja dotyczy innego pojazdu i należy do jednej grupy paliwa.

2. Normalność rozkładu zmiennej w grupach.

Normalność rozkładu cen w obu grupach sprawdzono za pomocą testu Shapiro–Wilka. Otrzymane wartości p były znacznie mniejsze od poziomu istotności, co wskazuje na istotne odstępstwa od rozkładu normalnego. Należy jednak zauważyć, że przy bardzo dużych próbach test Shapiro–Wilka ma wysoką moc i często prowadzi do odrzucenia hipotezy normalności nawet przy niewielkich odchyleniach.

Z uwagi na dużą liczebność prób oraz brak równości wariancji zastosowano test t-Studenta w wersji Welcha, który jest odporny na naruszenie tych założeń.

```
print("Diesel p-value:", shapiro_diesel.pvalue)
print("Petrol p-value:", shapiro_petrol.pvalue)

Diesel p-value: 1.891785062458934e-20
Petrol p-value: 1.4955499929705802e-15
```

Rysunek 5: Sprawdzono normalność rozkładu ceny w obu grupach za pomocą testu Shapiro-Wilka.

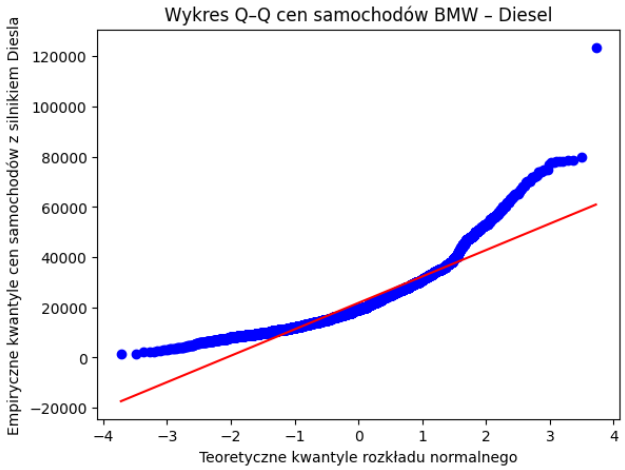


Rysunek 6: Wykres kwantyl–kwantyl dla aut dieselowych

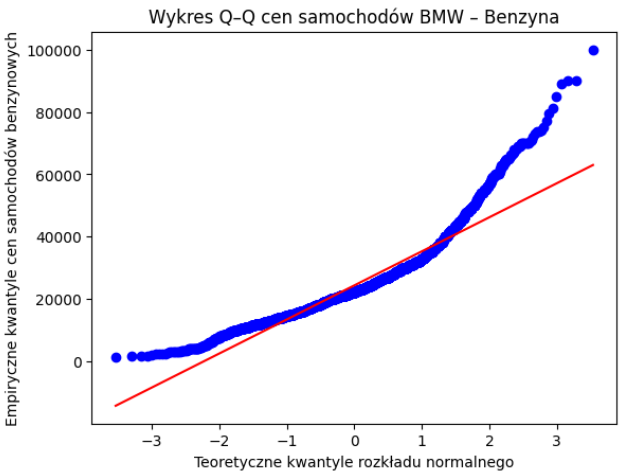


Rysunek 7: Wykres kwantyl–kwantyl dla aut benzynowych

### 2.1.3 Wyniki

Otrzymana wartość p była znacznie mniejsza od poziomu istotności $\alpha = 0.05$, co prowadzi do odrzucenia hipotezy zerowej. Oznacza to, że średnie ceny samochodów z silnikiem Diesla i benzynowym różnią się istotnie statystycznie. Znak statystyki testowej wskazuje, że samochody z silnikiem Diesla są przeciętnie tańsze od benzynowych.

```
print("Statystyka t:", t_stat)
print("p-value:", p_value)


Statystyka t: -10.837347932657433
p-value: 3.874127263514373e-27
```

Rysunek 8: Wyniki testu t-studenta w wersji Welcha

# 3 Analiza wariancji (ANOVA)

Analiza wariancji została przeprowadzona w celu porównania średnich cen samochodów BMW pomiędzy więcej niż dwiema grupami, zdefiniowanymi przez rodzaj paliwa.

## 3.1 Hipotezy

- Hipoteza zerowa ($H_0$): średnie ceny samochodów są jednakowe we wszystkich grupach rodzaju paliwa.
- Hipoteza alternatywna ($H_1$): co najmniej jedna z grup różni się istotnie statystycznie pod względem średniej ceny.

## 3.2 Założenia

Zakłada się niezależność obserwacji, gdyż każda obserwacja dotyczy innego pojazdu i należy do jednej grupy rodzaju paliwa. Sprawdzono jednorodność wariancji za pomocą testu Levene'a. Uzyskana wartość p była mniejsza od poziomu istotności, co wskazuje na istotne różnice wariancji pomiędzy grupami. Dodatkowo rozkłady cen w poszczególnych grupach wykazują odstępstwa od rozkładu normalnego, jednak przy dużej liczebności prób analiza wariancji pozostaje odporna na umiarkowane naruszenia tego założenia. Z tego względu zastosowano analizę wariancji ANOVA w wersji Welcha, która nie wymaga spełnienia założenia jednorodności wariancji.

```
levene_test = levene(*groups)

print("Levene p-value:", levene_test.pvalue)

Levene p-value: 0.00016008357888498256
```

Rysunek 9: Sprawdzono równość wariancji za pomocą testu Levene'a.

## 3.3 Wyniki

Wynik testu ANOVA Welcha wskazuje na istotne statystycznie różnice pomiędzy średnimi cenami samochodów w zależności od rodzaju paliwa. W celu identyfikacji konkretnych par grup różniących się istotnie zastosowano test post-hoc Gamesa–Howella.

```
print(welch_anova)

     Source  ddof1      ddof2          F         p-unc       np2
0  fuelType      4  16.256284  53.870575  3.570103e-09  0.015734
```

Rysunek 10: Wyniki testu ANOVA Welcha

Analiza post-hoc wskazuje, że najwyższe średnie ceny dotyczą pojazdów hybrydowych, które różnią się istotnie od pozostałych kategorii paliwa. Samochody benzynowe są przeciętnie droższe od dieslowskich, natomiast różnice pomiędzy pojazdami elektrycznymi i grupą „Other" nie są istotne statystycznie.

```
print(games_howell)
```

```
          A         B       mean(A)       mean(B)         diff           se  \
0    Diesel  Electric  21779.262986  18466.000000  3313.262986   549.473624
1    Diesel    Hybrid  21779.262986  27169.714765 -5390.451779   744.428465
2    Diesel     Other  21779.262986  18193.861111  3585.401875   852.982488
3    Diesel    Petrol  21779.262986  24360.271583 -2581.008598   238.158691
4  Electric    Hybrid  18466.000000  27169.714765 -8703.714765   905.776173
5  Electric     Other  18466.000000  18193.861111   272.138889   996.913166
6  Electric    Petrol  18466.000000  24360.271583 -5894.271583   568.310037
7    Hybrid     Other  27169.714765  18193.861111  8975.853654  1116.283269
8    Hybrid    Petrol  27169.714765  24360.271583  2809.443182   758.438379
9     Other    Petrol  18193.861111  24360.271583 -6166.410472   865.236476

           T           df          pval    hedges
0   6.029885     2.258958  6.356802e-02  0.295994
1  -7.241061   317.062789  3.385758e-11 -0.478828
2   4.203371    36.780716  1.430894e-03  0.320894
3 -10.837348  6593.153127  1.141975e-12 -0.228307
4  -9.609123    16.289356  3.646020e-07 -0.689023
5   0.272982    18.041722  9.986602e-01  0.054173
6 -10.371577     2.584983  1.279568e-02 -0.511369
7   8.040839   101.082036  1.753686e-11  0.741997
8   3.704247   341.473052  2.286357e-03  0.241719
9  -7.126850    38.939198  1.415498e-07 -0.537029
```

Rysunek 11: Wyniki testu Gamesa-Howella

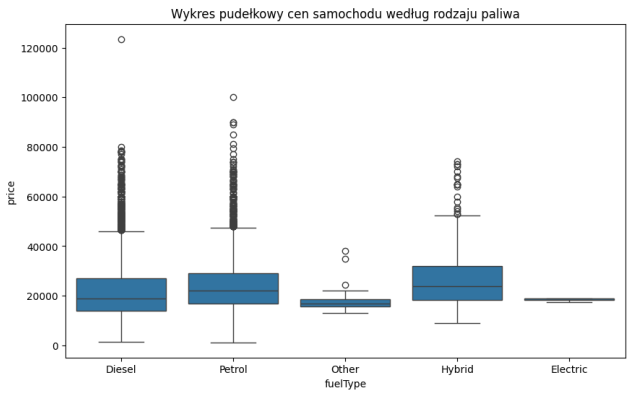


Rysunek 12: Wykres pudełkowy średnich cen samochodów w zależności od rodzaju paliwa

# 4 Testy nieparametryczne

Ze względu na brak normalności rozkładów zastosowano również testy nieparametryczne.

## 4.1 Test Manna–Whitneya

Test Manna–Whitneya został użyty jako nieparametryczny odpowiednik testu t-Studenta dla dwóch niezależnych prób.

- $H_0$: rozkłady cen samochodów Diesla i benzynowych są identyczne.
- $H_1$: rozkłady cen różnią się istotnie statystycznie.

```
print("Mann-Whitney U:", u_stat)
print("p-value:", mw_p)

Mann-Whitney U: 9958342.0
p-value: 1.5866096359458147e-45
```

Rysunek 13: Wyniki testu Manna–Whitneya

Otrzymana wartość p była mniejsza od poziomu istotności, co potwierdza istotne różnice pomiędzy rozkładami cen analizowanych grup.

### 4.2 Test Kruskala–Wallisa

Test Kruskala–Wallisa jest nieparametrycznym odpowiednikiem analizy wariancji. Jego zastosowanie pozwala na porównanie więcej niż dwóch grup bez założenia normalności rozkładu.

- $H_0$: rozkłady cen samochodów w poszczególnych grupach rodzaju paliwa są identyczne.
- $H_1$: co najmniej jedna z grup rodzaju paliwa różni się istotnie statystycznie pod względem rozkładu cen.

```
print("Kruskal-Wallis statystyka:", kw_stat)
print("p-value:", kw_p)

Kruskal-Wallis statystyka: 259.1712834335899
p-value: 6.879649237769231e-55
```

Rysunek 14: Wyniki testu Kruskala–Wallisa

Wynik testu wskazuje na istotne statystycznie różnice pomiędzy co najmniej jedną z grup rodzaju paliwa, co jest zgodne z wynikami uzyskanymi za pomocą ANOVA Welcha.

## 5 Analiza regresji wielorakowej

Analiza została wykonana metodą najmniejszych kwadratów (OLS). Celem analizy regresji wielorakowej było zbadanie wpływu wielu cech pojazdu jednocześnie na jego cenę. Zmienną objaśnianą była logarytmicznie przekształcona cena samochodu, co pozwoliło ograniczyć wpływ asymetrii rozkładu ceny i heteroskedastyczności.

Do modelu włączono zmienne ilościowe (rok produkcji, przebieg, pojemność silnika) oraz zmienne jakościowe zakodowane za pomocą zmiennych zero-jedynkowych (rodzaj paliwa, skrzynia biegów).

Model jako całość okazał się istotny statystycznie, co potwierdza wynik testu F ($F = 6244$). Wysoka wartość współczynnika determinacji $R^2$ ($R^2 = 0.839$) wskazuje, że znaczna część zmienności cen pojazdów została wyjaśniona przez zmienne uwzględnione w modelu. Największy wpływ na cenę ma rodzaj paliwa - czy auto jest elektryczne czy nie.

```
print(model.summary())

                            OLS Regression Results
==============================================================================
Dep. Variable:              log_price   R-squared:                       0.839
Model:                            OLS   Adj. R-squared:                  0.839
Method:                 Least Squares   F-statistic:                     6244.
Date:                Mon, 19 Jan 2026   Prob (F-statistic):               0.00
Time:                        06:18:20   Log-Likelihood:                 2403.5
No. Observations:               10781   AIC:                            -4787.
Df Residuals:                   10771   BIC:                            -4714.
Df Model:                           9
Covariance Type:            nonrobust
==========================================================================================
                             coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------------------
const                   -191.9760      2.589    -74.140      0.000    -197.052    -186.900
mileage                 -6.351e-06   1.22e-07    -52.219      0.000   -6.59e-06   -6.11e-06
year                       0.0998      0.001     77.865      0.000       0.097       0.102
engineSize                 0.3300      0.004     89.571      0.000       0.323       0.337
fuelType_Electric          0.5480      0.112      4.886      0.000       0.328       0.768
fuelType_Hybrid            0.2459      0.012     20.950      0.000       0.223       0.269
fuelType_Other             0.1591      0.033      4.885      0.000       0.095       0.223
fuelType_Petrol           -0.0129      0.004     -3.084      0.002      -0.021      -0.005
transmission_Manual       -0.1645      0.005    -30.398      0.000      -0.175      -0.154
transmission_Semi-Auto     0.0007      0.005      0.144      0.886      -0.008       0.010
==============================================================================
Omnibus:                     2163.962   Durbin-Watson:                   1.771
Prob(Omnibus):                  0.000   Jarque-Bera (JB):            10931.360
Skew:                           0.880   Prob(JB):                         0.00
```

Rysunek 15: Model regresji wielorakiej

## 5.1 Diagnostyka modelu

Test Breuscha-Pagana wskazuje na możliwość występowania heteroskedastyczności, jednak wykres reszt względem wartości dopasowanych (Rysunek 14) nie wykazuje ewidentnych oznak heteroskedastyczności. Dodatkowo test Shapiro–Wilka dla reszt wskazuje na odstępstwa od normalności, co przy dużej liczebności prób nie stanowi istotnego problemu interpretacyjnego. Normalność rozkładu reszt została dodatkowo oceniona graficznie za pomocą wykresu kwantyl-kwantyl (Q—Q). W centralnej części rozkładu punkty układają się w przybliżeniu wzdłuż linii prostej, co wskazuje na zbliżenie do rozkładu normalnego. Odchylenia obserwowane w ogonach rozkładu sugerują występowanie obserwacji odstających oraz pewną asymetrię, co jest typowe dla danych rynkowych. Uzyskany wykres potwierdza wnioski z testu Shapiro-Wilka, jednak skala odchyleń nie jest na tyle duża, aby całkowicie zdyskwalifikować model.

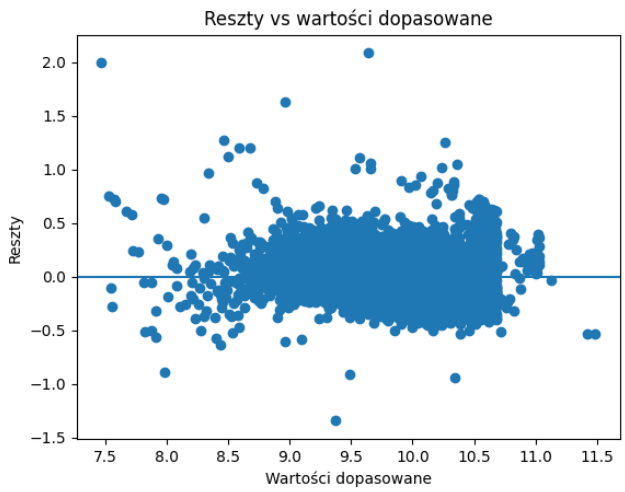


Rysunek 16: Reszty vs wartości dopasowane

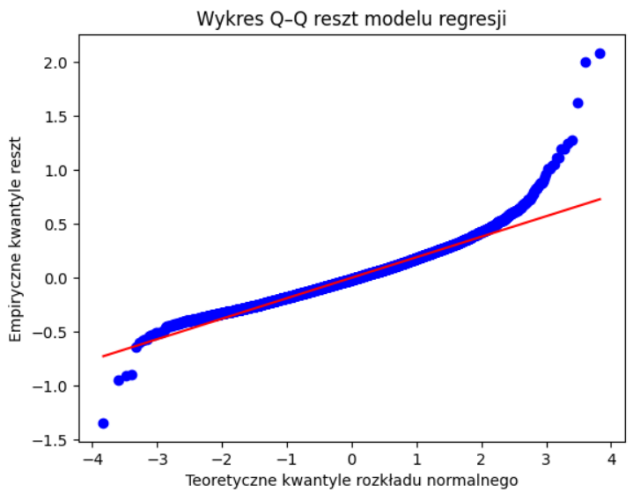


Rysunek 17: Wykres kwantyl-kwantyl modelu

```
shapiro_res = shapiro(residuals.sample(500, random_state=1))
print("Shapiro reszt p-value:", shapiro_res.pvalue)

bp_test = het_breuschpagan(residuals, model.model.exog)
print("Breusch-Pagan p-value:", bp_test[1])
Shapiro reszt p-value: 6.023576335785023e-19
Breusch-Pagan p-value: 2.520555056426286e-131
```

Rysunek 18: Wyniki testów Breuscha–Pagana i Shapiro-Wilka

W celu oceny współliniowości pomiędzy zmiennymi objaśniającymi obliczono współczynniki VIF (Variance Inflation Factor). Żadna zmienna nie przekracza wartości VIF = 5, więc multikolinearność nie jest problemem i nie usuwamy żadnej zmiennej na podstawie VIF. Na podstawie istotności statystycznej parametrów przeprowadzono uproszczenie modelu. Została usunięta jedna zmienna. Porównanie kryteriów informacyjnych AIC i BIC wykazało, że model uproszczony oferuje lepszą jakość dopasowania przy mniejszej liczbie parametrów. Kryterium AIC zmniejszyło się z -4787 do -4789 czyli o 2, co wskazuje na równoważność modeli. Kryterium BIC dla modelu uproszczonego zmniejszyło się z -4714 do -4723 (czyli o ok. 9), co wskazuje na wyraźną przewagę modelu uproszczonego w porównaniu z modelem pełnym. Spadek BIC wynika z redukcji liczby parametrów, przy zachowaniu zbliżonej jakości dopasowania

| | zmienna | VIF |
|---|---|---|
| 0 | const | 3.705774 |
| 1 | mileage | 2.686994 |
| 2 | year | 2.606127 |
| 3 | engineSize | 1.188833 |
| 4 | fuelType_Electric | 1.005438 |
| 5 | fuelType_Hybrid | 1.063893 |
| 6 | fuelType_Other | 1.014996 |
| 7 | fuelType_Petrol | 1.095532 |
| 8 | transmission_Manual | 1.510826 |
| 9 | transmission_Semi-Auto | 1.446090 |

Rysunek 19: Współczynniki VIF

```
model.pvalues
```

| | 0 |
|---|---|
| const | 0.000000e+00 |
| mileage | 0.000000e+00 |
| year | 0.000000e+00 |
| engineSize | 0.000000e+00 |
| fuelType_Electric | 1.041516e-06 |
| fuelType_Hybrid | 1.481082e-95 |
| fuelType_Other | 1.051326e-06 |
| fuelType_Petrol | 2.045173e-03 |
| transmission_Manual | 8.568244e-195 |
| transmission_Semi-Auto | 8.856991e-01 |

Rysunek 20: Istotnosć parametrów modelu (p-values)

```
R2 model pełny: 0.8391567872827231
R2 model uproszczony: 0.839156478698419
AIC model pełny: -4787.09611100917
AIC model uproszczony: -4789.075427238091
BIC pełny: -4714.240704963779
BIC uproszczony: -4723.505561797238
Liczba parametrów - model pełny: 10.0
Liczba parametrów - model uproszczony: 9.0
```

Rysunek 21: Porównanie modelu i modelu uproszczonego